



POLITECNICO
MILANO 1863

SCUOLA DI INGEGNERIA INDUSTRIALE
E DELL'INFORMAZIONE

**Classificazione automatica di immagini
dermoscopiche tramite CNN: sistemi di deep
learning per la diagnosi di melanoma**

TESI DI LAUREA TRIENNALE IN INGEGNERIA BIOMEDICA

Autrice: Sacilotto Greta

Student ID: 10909142

Relatore: Prof. Alberto Antonietti

Co-relatore: Prof. Juan Pedro Dominguez-Morales

Anno accademico: 2025-2026

Abstract

Il melanoma cutaneo è una neoplasia aggressiva e la diagnosi precoce è un fattore determinante ai fini prognostici. La distinzione tra melanoma e lesioni benigne rimane ad oggi ancora complessa anche con l'ausilio della dermoscopia a causa dell'elevata variabilità morfologica delle lesioni e della possibile sovrapposizione dei segni clinici. In questo contesto le reti neurali convoluzionali (CNN) rappresentano uno strumento promettente per fornire un supporto automatizzato e riproducibile alla classificazione delle immagini dermoscopiche.

Questo progetto ha confrontato tre architetture CNN preaddestrate su ImageNet: Vgg16, ResNet50 e DenseNet121 con l'obiettivo di effettuare una classificazione binaria tra lesioni benigne e melanoma maligno. Gli esperimenti sono stati realizzati in ambiente Google Colab mediante TensorFlow e Keras. È stato utilizzato un dataset pubblico disponibile su Kaggle composto da 2637 immagini di training e 660 immagini di test derivanti dall'archivio ISIC. Le immagini sono state ridimensionate a 224×224 pixel e i modelli sono stati addestrati mediante la tecnica del transfer learning.

Nella prima fase è stata definita una baseline comune in cui i modelli sono stati privati del classificatore originale e utilizzati come feature extractor con backbone congelata. A ciascuna rete è stata aggiunta la stessa testa classificatoria, composta da Global Average Pooling, un layer Dense da 128 neuroni con attivazione ReLU, Dropout pari a 0,5 e un'uscita sigmoide per la classificazione binaria. Per ciascun modello è stata usata la medesima configurazione di training con ottimizzatore Adam e 10 epoche massime di allenamento. Per aumentare la robustezza del confronto, la baseline è stata successivamente valutata mediante cross-validation stratificata a 3 fold considerando accuracy, sensitivity, specificity, F1-score, AUC e ROC curve. DenseNet121 ha ottenuto le migliori prestazioni complessive nella baseline, con accuracy media pari a 0,8479, F1-score pari a 0,8346 e AUC pari a 0,9363 nella validation. Vgg16 ha mostrato una sensitivity più elevata di 0,8688 associata, tuttavia, a una specificity inferiore di 0,7708. ResNet50 ha evidenziato un comportamento critico, classificando quasi tutti i campioni come benigni senza una reale capacità di generalizzazione e con sensitivity media di 0,0033 e F1-score di 0,0066, nonostante una specificity di 0,9979.

Nella seconda fase sono state introdotte strategie di ottimizzazione. Per ResNet50, a seguito dei primi risultati, sono stati applicati preprocessing specifico, fine-tuning

parziale degli ultimi 30 layer, learning rate ridotto ed EarlyStopping. Vgg16 e DenseNet121 sono state invece ottimizzate congiuntamente mediante una maggiore data augmentation, regolarizzazione L2, Batch Normalization, aumento del Dropout e gestione dinamica del learning rate. ResNet50 ha mostrato il miglioramento più marcato raggiungendo accuracy media di 0,8786, sensitivity 0,8972, F1-score 0,8705 e AUC di 0,9516. DenseNet121 ha mantenuto prestazioni elevate e bilanciate mostrando miglioramenti minimi. Vgg16 ha migliorato accuracy, specificity e AUC, con una lieve riduzione della sensitivity.

Infine, è stata condotta un'analisi tramite l'uso di Grad-CAM per integrare alla valutazione quantitativa anche un confronto qualitativo delle regioni visive maggiormente associate alla predizione. L'explainability risulta essere un passaggio fondamentale per verificare la coerenza clinica delle predizioni del modello rispetto al dominio dermoscopico. DenseNet121 ha mostrato mappe generalmente plausibili e ben coerenti con la lesione, Vgg16 ha presentato un'attenzione più diffusa mentre ResNet50, dopo l'ottimizzazione, ha prodotto mappe più ricche e meno ripetitive rispetto alla configurazione baseline che mancava di specificità. Questi risultati sono coerenti con le metriche registrate durante l'analisi quantitativa.

Nel complesso, il lavoro evidenzia che le prestazioni dipendono non solo dalla scelta della CNN, ma anche dal preprocessing, dalla strategia di transfer learning e dall'ottimizzazione del training. Nelle condizioni sperimentali adottate ResNet50 è risultato il caso più istruttivo passando da prestazioni critiche nella prima fase con baseline comune ad ottenere le metriche medie migliori a seguito dell'ottimizzazione mirata. Questi risultati suggeriscono che l'adattamento parziale del backbone e l'utilizzo del preprocessing coerente con ImageNet siano stati particolarmente importanti nel caso di ResNet50. DenseNet121 è risultato invece il modello che ha mostrato maggiore robustezza fin dalla prima fase sperimentale. La cross-validation è stata limitata a tre fold per ragioni di tempo e di risorse computazionali e non consente quindi di affermare una superiorità statisticamente significativa di un'architettura rispetto ad un'altra.

English Abstract

Cutaneous melanoma is an aggressive neoplasm for which early diagnosis is a decisive prognostic factor. Even with the aid of dermoscopy distinguishing melanoma from benign lesions remains challenging because of the high morphological variability of lesions and the possible overlap of clinical signs. In this context, convolutional neural networks (CNNs) represent a promising tool for providing automated and reproducible support for the classification of dermoscopic images.

This project compared three CNN architectures pretrained on ImageNet: Vgg16, ResNet50, and DenseNet121 with the aim of performing binary classification between benign lesions and malignant melanoma. The experiments were conducted in the Google Colab environment using TensorFlow and Keras. A public Kaggle dataset consisting of 2,637 training images and 660 test images from the ISIC archive was used. Images were resized to 224×224pixels and the models were trained using transfer learning.

In the first phase a common baseline was defined in which the original classifier of each model was removed and the networks were used as feature extractors with a frozen backbone. The same classification head was added to each network, consisting of Global Average Pooling, a Dense layer with 128 neurons and ReLU activation, a Dropout layer with a rate of 0.5, and a sigmoid output layer for binary classification. The same training configuration was used for all models, with the Adam optimizer and a maximum of 10 training epochs. To increase the robustness of the comparison, the baseline was subsequently evaluated through stratified 3-fold cross-validation, considering accuracy, sensitivity, specificity, F1-score, AUC, and ROC curves.

DenseNet121 achieved the best overall baseline performance with a mean accuracy of 0.8479, an F1-score of 0.8346, and an AUC of 0.9363. Vgg16 showed a higher sensitivity of 0.8688, although this was associated with a lower specificity of 0.7708. ResNet50 exhibited critical behaviour, classifying almost all samples as benign, with no effective ability to generalise to the malignant class. Its mean sensitivity was 0.0033 and its F1-score was 0.0066, despite a specificity of 0.9979.

In the second phase optimisation strategies were introduced. For ResNet50, following the initial results, model-specific preprocessing, partial fine-tuning of the final 30 layers, a reduced learning rate, and EarlyStopping were applied. Vgg16 and DenseNet121 were jointly optimised through stronger data augmentation, L2 regularisation, Batch Normalization, increased Dropout, and dynamic learning-rate

management. ResNet50 showed the most substantial improvement, achieving a mean accuracy of 0.8786, a sensitivity of 0.8972, an F1-score of 0.8705, and an AUC of 0.9516. DenseNet121 maintained high and balanced performance, showing only minor improvements. Vgg16 improved in accuracy, specificity, and AUC, with a slight reduction in sensitivity.

Finally, Grad-CAM analysis was performed to complement the quantitative evaluation with a qualitative comparison of the visual regions most strongly associated with model predictions. Explainability represents a fundamental step for assessing whether model predictions are clinically coherent with the dermoscopic domain. DenseNet121 generally produced plausible activation maps well aligned with the lesion, Vgg16 showed more diffuse attention. After optimisation, ResNet50 generated richer and less repetitive maps than in the baseline configuration. These observations were consistent with the metrics obtained during the quantitative analysis.

Overall, this work highlights that performance depends not only on the selected CNN architecture, but also on preprocessing, transfer-learning strategy, and training optimisation. Under the experimental conditions adopted, ResNet50 was the most informative case: it progressed from critical performance in the common baseline to the best mean metrics after targeted optimisation. These results suggest that partial adaptation of the backbone and the use of ImageNet-consistent preprocessing were particularly important for ResNet50. In contrast, DenseNet121 was the model that demonstrated the greatest robustness from the first experimental phase. Cross-validation was limited to three folds because of time and computational-resource constraints, therefore, the results do not support a claim of statistically significant superiority of one architecture over another.

Indice

Abstract.....	i
English Abstract.....	iii
Indice.....	v
Introduzione	1
1.1. Melanoma	1
1.1.1. Fattori di rischio.....	1
1.1.2. Aumento dei casi diagnosticati e sovradiagnosi	2
1.1.3. Sottotipi istologici di melanoma	3
1.1.4. Il problema del mimetismo dermoscopico: melanoma vs lesioni benigne	4
1.1.5. Diagnosi precoce come fattore critico	5
1.1.6. Tecniche e limiti diagnostici	6
1.1.7. Necessità di nuove tecniche di diagnosi.....	7
1.2. Stato dell'arte	8
1.2.1. Convolutional Neural Network (CNN)	8
1.2.2. Struttura e processo di apprendimento delle CNN	9
1.2.3. Performance di architetture esistenti.....	10
1.2.4. Confronto con tecniche diagnostiche tradizionali.....	11
1.2.5. Limiti del modello e necessità di futuri sviluppi.....	12
1.3. Obiettivi del progetto.....	13
2 Materiali e metodi.....	15
2.1. Dataset e Ambiente di lavoro	15
2.2. Prima fase: confronto tra Vgg16, ResNet50 e DenseNet121 attraverso una baseline comparativa comune	16
2.2.1. Preprocessing: ridimensionamento, normalizzazione e data augmentation	16
2.2.2. Transfer learning	17
2.2.3. Training e validation.....	18
2.2.4. Test	19
2.2.5. Cross-Validation.....	20
2.3. Seconda fase: ottimizzazione.....	21

2.3.1.	Ottimizzazione mirata di ResNet50.....	21
2.3.2.	Ottimizzazione congiunta di Vgg16 e DenseNet121.....	22
2.3.3.	Cross-validation.....	24
2.4.	Explainability con Grad-CAM.....	24
3	Risultati	26
3.1.	Prima fase: baseline comune.....	26
3.1.1.	Boxplot	28
3.1.2.	Confusion matrix.....	30
3.1.3.	Roc-curve prima fase	32
3.2.	Seconda fase: ottimizzazione	33
3.2.1.	Boxplot	35
3.2.2.	Confusion matrix.....	37
3.3.	Grad-CAM.....	38
4	Discussione.....	44
4.1.	Prima fase	44
4.1.1.	Vgg16.....	44
4.1.2.	ResNet 50	44
4.1.3.	DenseNet121.....	45
4.2.	Seconda fase: ottimizzazione	46
4.2.1.	Vgg16.....	46
4.2.2.	Resnet50	46
4.2.3.	DenseNet121.....	47
4.3.	Grad-CAM.....	47
5	Conclusione	49
	Bibliografia	51
	Lista di figure.....	53
	Lista di tabelle	54
	Ringraziamenti.....	56

Introduzione

1.1. Melanoma

Il melanoma cutaneo è uno delle forme più aggressive di tumore cutaneo ed è responsabile della maggior parte dei decessi per cancro alla pelle a livello mondiale a causa della sua elevata capacità di creare metastasi. Ha origine dalla proliferazione incontrollata di melanociti, cellule produttrici di melanina situate nello strato basale dell'epidermide e derivanti dalla cresta neurale. Quando i melanociti si trasformano in melanoma possono metastatizzare e sviluppare meccanismi di evasione immunitaria, fenomeno che può svilupparsi in qualsiasi organo contenente melanociti, incluse superfici di mucose, parte posteriore dell'occhio e meningi.[1], [2]

Il melanoma cutaneo (CM) rappresenta circa l'1% di tutte le neoplasie cutanee ed è responsabile del 66-83% dei decessi correlati a tumori della pelle nei paesi con elevata mortalità a causa di questa patologia.[2]

Nel 2022, GLOBOCAN ha riportato 331.722 nuovi casi e 58.667 decessi a livello globale[3] e negli Stati Uniti il melanoma è il quinto tumore più comune rappresentando circa il 5% delle totalità di nuovi casi di cancro diagnosticati ogni anno. [2]

Il tasso di incidenza più alta di questa malattia è stata osservata nelle regioni con alto HDI come Oceania, Nord America ed Europa, dove le popolazioni a pelle chiara sono esposte a sostanziali livelli di UVR.[3]

Si prevede che entro il 2040 il numero di casi aumenterà del 50% a livello globale.[2]

1.1.1. Fattori di rischio

Il principale rischio ambientale è rappresentato dall'esposizione prolungata a radiazioni ultraviolette (UVR) responsabili dell'insorgenza di circa il 75% di nuovi casi di melanoma.[2]

L'esposizione a raggi UV favorisce la formazione di alterazioni genetiche nelle cellule melanocita, fattore che aumenta quindi la probabilità di trasformazione in tumore maligno.

Il melanoma, oltre che dall'esposizione intermittente e cumulativa al sole e dalle scottature solari, ha origine a seguito dell'interazione di numerosi altri fattori di rischio:

- Predisposizione genetica e ereditarietà;
- Caratteristiche individuali: sesso, età e obesità. Il rischio aumenta con l'età mentre le donne presentano generalmente un tasso di incidenza minore e una prognosi migliore rispetto gli uomini;
- Fototipo cutaneo chiaro (Fitzpatrick I-II);
- Condizioni metaboliche;
- Farmaci: corticosteroidi, antistaminici, farmaci antinfiammatori non steroidei, metformina, antibiotici e farmaci ipolipemizzanti;
- Comportamenti legati allo stile di vita: il fumo, il consumo di alcol e di caffè, l'alimentazione, l'attività fisica e i ritmi circadiani.[4]

1.1.2. Aumento dei casi diagnosticati e sovradiagnosi

Uno studio ha dimostrato che dal 1990 al 2021 il numero di nuovi casi di CM è aumentato con un incremento globale del 143,8% e solamente nel 2022 a livello mondiale sono stati diagnosticati 330.000 nuovi casi di melanoma con 60.000 decessi.[5]

Negli Stati Uniti l'incidenza di melanoma è aumentato significativamente negli ultimi decenni, passando da 8,8 casi per 100.000 persone nel 1975 a circa 28,4 casi per 100.000 persone oggi.[6]

L'incidenza di questa patologia è in crescita in modo costante del 2-3% annualmente.[3]

Uno studio condotto nel 2025 da N. Cirillo attraverso l'analisi di dati epidemiologici globali (GLOBOCAN, 162 paesi nel 2022) ha evidenziato la correlazione tra l'aumento dei casi diagnosticati e la diffusione di programmi di sensibilizzazione, screening e cambiamento dei criteri diagnostici. Difatti, l'aumento all'esposizione a luce ultravioletta e ad altri fattori di rischio potrebbe essere solo una delle cause di questo fenomeno. Le tendenze globali hanno mostrato un aumento significativo nei casi diagnosticati ma un tasso di mortalità che aumenta molto più lentamente o rimane pressoché invariata.

Una sorveglianza più intensa, senza un significativo miglioramento degli strumenti diagnostici, potrebbe aver portato a un fenomeno di sovradiagnosi che si verifica con un'incidenza tra il 29% e il 60%. Aumentano i trattamenti e l'incidenza di diagnosi ma il tasso reale di malattia clinicamente significativa non è cambiato.

È quindi importante e fondamentale lo sviluppo di strumenti di diagnosi più accurati e precisi per ridurre:

- diagnosi non necessarie;
- biopsie non necessarie;
- trattamenti di lesioni che probabilmente non sarebbero diventate letali;
- possibili danni associati al trattamento non necessario.
- Una corretta distinzione tra melanomi clinicamente rilevanti, quelli destinati a progredire e le lesioni indolenti con bassa probabilità di diventare letali al fine di poter effettuare trattamenti più specifici e adatti.[7]

1.1.3. Sottotipi istologici di melanoma

Il melanoma cutaneo è una neoplasia biologicamente diversificata caratterizzata da distinti sottotipi istopatologici che influenzano significativamente la diagnosi, la prognosi e la gestione della malattia.

Tabella 0. Sottotipi istologici di melanoma.

Sottotipo	Sedi comuni	Caratteristiche cliniche	Pattern di crescita	Prognosi
Melanoma superficiale a diffusione (SSM) (60-70% dei casi)	Tronco, estremità prossimali	Lesione pigmentata asimmetrica con margini irregolari	Prima radiale poi invasione verticale	Favorevole se identificato precocemente
Melanoma nodulare (NM) (15-30% dei casi)	Tronco, testa e collo	Nodulo uniformemente pigmentato a rapida crescita, spesso ulcerato	Rapida crescita, può ulcerarsi, no crescita radiale	A causa di diagnosi tardiva ha mortalità elevata
Melanoma lentigo maligna (LMM)	Viso, collo, avambracci negli anziani	Macula pigmentata piatta a lento ingrandimento	Sviluppa a partire dalla lentigo maligna nell'arco di molti anni	Comportamento aggressivo se non trattato precocemente

Sottotipo	Sedi comuni	Caratteristiche cliniche	Pattern di crescita	Prognosi
Melanoma lentiginoso acrale (ALM) (2-8% dei casi)	Palmi, piante, letti ungueali	Aspetto aspecifico, spesso diagnosticata tardivamente	crescita lentiginosa con melanociti atipici a livello della giunzione dermo epidermica	Risposta limitata alle terapie mirate convenzionali e prognosi peggiore a causa di diagnosi tardiva
Melanoma desmoplastico (DM) (1-4% dei casi)	Testa e collo	Compatto, amelanotico, simile a una cicatrice	Pattern infiltrativo fibroso	Metastasi linfonodali rare ma recidiva locale è più frequente

Il sottotipo istologico ha una correlazione con il comportamento tumorale e con gli esiti clinici e fornisce quindi informazioni rilevanti a supporto della pianificazione chirurgica e della terapia adiuvante.

Tuttavia, a causa della sovrapposizione delle caratteristiche e della limitata caratterizzazione delle tipologie rare rimangono diverse difficoltà diagnostiche nella classificazione del sottotipo istologico.[5]

1.1.4. Il problema del mimetismo dermoscopico: melanoma vs lesioni benigne

Una delle difficoltà centrali della diagnosi consiste nella distinzione tra melanoma maligno e lesioni cutanee benigne. Tra gli errori più frequenti vi sono casi non riconosciuti, ovvero falsi negativi, e casi benigni che vengono rimossi senza una reale necessità, i falsi positivi.

Questo è conseguenza del fatto che una quota di casi di melanoma presenta quadri dermoscopici equivoci e ambigui. Le caratteristiche dermoscopiche tipiche di melanoma quali rete pigmentaria atipica, varietà di colori, asimmetria delle strutture e aree prive di struttura non sempre sono sufficienti a identificare i casi maligni. D'altra parte, segni singoli come globuli periferici o presenza di peli terminali non sempre bastano a considerare la lesione benigna.[8]

La regola dell'ABCD dell'esame visivo talvolta manca di specificità in quanto i segni di melanoma possono comparire anche in lesioni benigne. In particolare, questa tecnica risulta poco accurata per melanomi di diametro piccolo inferiore a 6mm.

Oltre che alle difficoltà nella distinzione tra melanoma e nevi, spesso i melanomi verrucosi possono sembrare cheratosi seborroiche. Al contrario, in zone come testa e collo l'assenza di segni dermoscopici di cheratosi attinica pigmentata o di cheratosi seborroica piatta porta a classificare erroneamente queste lesioni come melanoma lentigo maligna.[9]

La dermoscopia riduce le biopsie non necessarie ma non le elimina in quanto questa tecnica non è sempre precisa e inequivocabile: alcuni melanomi esprimono solamente alcuni dei criteri degli algoritmi diagnostici.

1.1.5. Diagnosi precoce come fattore critico

La diagnosi precoce e il trattamento tempestivo della malattia sono essenziali e rappresentano i fattori determinanti più importanti per il successo terapeutico e la probabilità di sopravvivenza.

Il melanoma ha il potenziale di metastatizzare attraverso il sistema linfatico e il flusso sanguigno ad altri organi, inclusi polmoni, fegato, cervello e ossa.[1]

I melanomi in stadio iniziale sono altamente curabili. La prognosi per pazienti con malattia in fase localizzata è di norma eccellente con una sopravvivenza relativa a 5 anni superiore al 99%.

Al contrario, la diagnosi di melanoma in uno stadio avanzato rappresenta una significativa sfida terapeutica con sopravvivenza relativa a 5 anni che scende al 74,8% in caso di coinvolgimento dei linfonodi regionali e solamente al 35,0% in presenza di malattia metastatica a distanza.[2], [5]

Nonostante i progressi complessivi, persistono significative disuguaglianze diagnostiche. Gli individui con tonalità cutanee più scure spesso giungono alla diagnosi in stadi più avanzati e presentano esiti peggiori. Negli Stati Uniti, la sopravvivenza media totale a cinque anni è del 94% tra i pazienti bianchi, ma solo del 70% tra i pazienti con pelle scura. Queste differenze statistiche riflettono bias demografici con la necessità etica di trovare strumenti di diagnosi più oggettivi e precisi per colmare le disparità.[3]

Da questi dati risulta evidente come la sopravvivenza al melanoma è molto buona se diagnosticato in fase localizzata ma scende drasticamente se la malattia viene

diagnosticata tardivamente in fase metastatica, risulta quindi fondamentale e necessario riuscire a effettuare diagnosi precoci e tempestive per questa patologia.

Attualmente circa il 15% dei pazienti riceve una diagnosi in fase metastatica regionale o a distanza.[6]

1.1.6. Tecniche e limiti diagnostici

La difficoltà nel riconoscere tempestivamente tutti i nuovi casi di melanoma nella loro fase localizzata è determinata dalla mancanza di strumenti di diagnosi sufficientemente oggettivi e accurati.

La diagnosi convenzionale di melanoma rimane laboriosa e può essere influenzata da diversi fattori, tra cui l'esperienza dello specialista e l'alta variabilità visiva delle lesioni, le quali, in fase iniziale spesso non presentano caratteri distintivi evidenti. Un'altra difficoltà significativa rimane la distinzione tra una lesione benigna e una maligna.

Il metodo maggiormente utilizzato per la diagnosi consiste in una prima valutazione basata su un esame visivo supportato dai criteri ABCDE e del segno del "*brutto anatroccolo*".[3]

Come si può notare dai dati tabella 1.2. sensibilità e specificità della diagnosi attraverso valutazione clinica presentano un'alta variabilità in base all'esperienza del medico che la effettua.

Tabella 2. Sensibilità e specificità dell'**esame clinico visivo** per la diagnosi di melanoma.[10]

Medico	Sensibilità	Specificità
Dermatologo esperto	76,9%	89,1%
Dermatologo inesperto	78,3%	66,2%
Medici di medicina generale	37,5%	84,6%

Convenzionalmente, a seguito dell'esame visivo la lesione può essere analizzata tramite dermoscopia, una tecnica di ingrandimento che utilizza luce visibile e che consente un esame più dettagliato della pelle rispetto all'esame effettuato ad occhio nudo alone.[11]

Questa tecnica, sebbene migliori l'accuratezza diagnostica, rimane anch'essa soggettiva e dipendente dallo specialista che la effettua, come si può facilmente notare nella tabella 3.

Tabella 3. Sensibilità e specificità della **dermoscopia** per la diagnosi di melanoma.[10]

Medico	Sensibilità	Specificità
Dermatologo esperto	85,7%	81,3%
Dermatologo inesperto	78,0%	69,5%
Medici di medicina generale	49,5%	91,3%

A seguito dell'esame visivo e dermoscopia, le lesioni sospette richiedono infine l'escissione e la conferma istopatologica, che costituisce il gold standard per la stadiazione e la gestione clinica. Questo percorso articolato in più fasi richiede molte risorse ed è spesso inefficiente. In molti sistemi sanitari, il numero di biopsie necessarie supera nove, una criticità aggravata dalla carenza di personale specializzato in dermatologia.[3]

Considerando solo visite effettuate da dermatologi esperti, la soglia di sensibilità attuale per l'esame visivo è quindi del 76,9% e del 85,7% per la dermoscopia, valori che lasciano non diagnosticati numerosi casi clinici.[10]

1.1.7. Necessità di nuove tecniche di diagnosi

A causa del potenziale metastatico del melanoma la sua diagnosi e trattamento precoci risultano quindi essere gli strumenti più importanti per il successo terapeutico. Il fallimento di diagnosi in fase localizzata può portare gravi conseguenze per il paziente e nuocere sulle prospettive di cura e sopravvivenza.

Nei casi in cui, a seguito di biopsia, risulti un caso di falso-positivo come un nevo melanocitico o una cheratosi seborroica, il paziente sarà andato in contro a procedure diagnostiche non necessarie, sottoponendosi a rischi chirurgici, formazione di cicatrici, stress, perdita di giorni di lavoro e costi di viaggio oltre che al sovraccarico non necessario del Sistema Sanitario e ai costi della biopsia.

La diagnosi tardiva aggrava inoltre le spese dei Sistemi Sanitari Pubblici. Uno studio condotto nel 2009 ha mostrato che il 95,8% di tutta la spesa adibita alla cura di melanoma nello stato di São Paulo è stata impiegata per i trattamenti di pazienti in stadi avanzati III e IV. [12]

Risulta quindi fondamentale il miglioramento dell'accuratezza diagnostica sia per il successo terapeutico e la sicurezza dei pazienti coinvolti che per un utilizzo mirato delle risorse del sistema sanitario.

1.2. Stato dell'arte

Negli ultimi anni tecniche di deep learning applicate alla diagnosi dei tumori cutanei hanno suscitato grande interesse in ambito scientifico.

Alcuni studi recenti hanno dimostrato che il supporto decisionale assistito agli specialisti da parte dell'AI può migliorare le performance diagnostiche dei non-specialisti del 10-15% riducendo anche di quasi il 60% la gestione errata di lesioni maligne. Lo sviluppo e il miglioramento dell'affidabilità clinica di nuovi strumenti che supportano le decisioni dei medici rappresenta quindi uno strumento promettente per migliorare la precisione nella diagnosi di melanoma.[3]

Lo studio condotto da Tognetti et al. [13] attraverso l'analisi di 20 studi basati sulle reti neurali convoluzionali (CNN) e reti neurali convoluzionali profonde (DCNN) ha mostrato quanto questi algoritmi possano raggiungere performance elevate con valori medi di accuratezza pari all'83,99%, sensibilità pari al 77,74% e specificità pari all'80,61% e mostrando un basso numero di falsi positivi.

Globalmente sono emersi risultati promettenti e incoraggianti ma, contemporaneamente, sono emerse alcune discrepanze riguardo la validazione in contesti clinici, metodologia degli studi e presentazione dei risultati.[13]

Non è quindi sufficiente basarsi solamente sugli elevati valori numerici di accuratezza riportati da questi strumenti ma rimane fondamentale valutare anche il tipo di dataset, modalità di suddivisione dati, validazione, confronto con dermatologi esperti e una buona rappresentatività clinica.

1.2.1. Convolutional Neural Network (CNN)

Una rete neurale convoluzionale è una rete neurale profonda progettata per elaborare dati con struttura a griglia, come le immagini. Un'immagine viene rappresentata come una matrice di numeri, che corrispondono ai valori dei pixel. La rete applica progressivamente filtri convoluzionali all'immagine di ingresso, generando mappe di attivazione che rappresentano caratteristiche visive di complessità crescente.[14], [15]

Le CNN sono tra i migliori algoritmi di computer vision (segmentazione, classificazione, rilevamento oggetti) e tra le loro caratteristiche principali vi sono:

- Riconoscere pattern complessi: bordi irregolari, varianza di colore, simmetria delle lesioni;
- Capacità di apprendere feature complesse dai dati;
- Integrazione di informazioni locali e globali;
- Capacità di classificazione delle immagini in categorie.

Contrariamente agli approcci di diagnosi tradizionali basati sull'estrazione separata di tratti quali forma, colore e texture, le CNN sono in grado di integrare sia informazioni locali che globali dell'immagine. Queste capacità permettono di migliorare accuratezza ed efficienza dei modelli di deep learning nell'analisi di immagini. [16]

1.2.2. Struttura e processo di apprendimento delle CNN

Le CNN sono formate da numerosi layer, spesso decine o centinaia, che elaborano progressivamente l'immagine riconoscendo prima gli elementi più semplici (bordi, linee, texture) fino ad arrivare, nei layer più avanzati, a combinare queste informazioni per riconoscere strutture e caratteristiche complesse.

I layer fondamentali delle CNN sono i seguenti:

- **Convolutional layer:** è il layer principale, rileva pattern attraverso l'utilizzo di piccoli filtri (kernel) che scorrono sull'immagine o sul tensore d'ingresso. Attiva le regioni rilevanti dell'immagine al fine di ottenere una feature map, ognuna delle quali rappresenta una determinata caratteristica.
- **Pooling layer:** riduce le dimensioni delle feature map diminuendo i parametri con lo scopo di ridurre il costo computazionale e conservare le informazioni più rilevanti.
- **Activation function (ReLU):** siccome l'operazione di convoluzione è lineare, per apprendere relazioni complesse l'uscita della convoluzione viene normalmente inviata alla funzione di attivazione che introduce non linearità. Tra queste, la funzione più utilizzata è *Rectified Linear Unit* (ReLU), che trasforma i valori negativi in zero e mantiene i positivi.
- **Layer completamente connessi:** utilizzano le caratteristiche estratte per produrre un risultato finale.

Le CNN estraggono e combinano automaticamente caratteristiche sempre più complesse che vengono infine utilizzate per produrre una classificazione finale.

Fasi del processo di apprendimento di una CNN:

1. **Propagazione in avanti** (forward propagation): l'immagine attraversa progressivamente i layer estraendo caratteristiche rilevanti e producendo una predizione in output.

2. **Calcolo della funzione di perdita** (loss function): misura quanto la previsione sia coerente con l'etichetta. Se la risposta prevista è lontana dalla risposta corretta la perdita è elevata.
3. **Propagazione all'indietro** (backpropagation): metodo usato per calcolare il contributo di ogni parametro all'errore.
4. **Aggiornamento dei parametri tramite discesa del gradiente**: il gradiente indica la direzione nella quale la funzione di perdita aumenta più rapidamente. Per ridurre la perdita, i parametri vengono modificati nella direzione opposta. Il learning rate determina l'ampiezza dell'aggiornamento: se è troppo grande l'addestramento può diventare instabile mentre se è troppo piccolo l'apprendimento può essere troppo lento.[15]

L'efficacia di questi modelli non dipende unicamente dall'architettura ma anche dalla qualità dei dati, dal tipo di pre-processing, dal processo di addestramento e dalla corretta valutazione e utilizzo del modello.

1.2.3. Performance di architetture esistenti

Nell'ambito della classificazione delle lesioni cutanee numerose architetture CNN sono state utilizzate attraverso la tecnica di transfer learning, la quale risulta particolarmente utile quando i dataset disponibili per il training risultano limitati, come nel caso dell'ambito medico.

Tra le architetture più diffuse vi sono:

- **Vgg16**: ha una struttura relativamente semplice e sequenziale costituita da blocchi convoluzionali con filtri 3x3, activation functions e operazioni di max pooling. Utilizza tuttavia un numero molto elevato di parametri che aumenta il costo computazionale e il rischio di overfitting.
- **ResNet50**: utilizza connessioni residue che permettono di trasferire direttamente l'input di un blocco alla sua uscita. In questo modo la propagazione del gradiente è facilitata consentendo di addestrare reti più profonde. Questa architettura contiene 50 layer dotati di pesi e richiede molta meno memoria rispetto a VGG, anche grazie all'utilizzo del global average pooling nella fase di classificazione. ResNet50 è uno dei backbone più diffusi in medical imaging e rappresenta spesso il principale termine di confronto per nuove architetture.

- **DenseNet121**: collega le feature map dei layer precedenti ai layer successivi tramite concatenazione. È progettata quindi per migliorare la propagazione delle informazioni e favorire il riutilizzo delle caratteristiche mantenendo un numero di parametri generalmente inferiore rispetto a reti tradizionali di comparabile profondità.

Questi tre modelli rappresentano quindi tre approcci progettuali differenti.

Uno studio condotto da Adebisi et al. ha evidenziato come queste architetture possano ottenere risultati competitivi nella classificazione delle lesioni cutanee ma le prestazioni dei modelli dipendono fortemente dal dataset utilizzato e dalla metodologia sperimentale adottata.

Ad oggi la letteratura sul deep learning applicato al melanoma è ampia ma solo una parte degli studi presenta caratteristiche sufficienti per un confronto sistematico.

Lo studio ha utilizzato 770 immagini dermoscopiche provenienti dall'University of Missouri Healthcare. Sono stati creati tre dataset: il dataset originale, un dataset in cui erano stati rimossi i peli solo dalle immagini che li contenevano e un dataset in cui la rimozione dei peli era stata applicata a tutte le immagini.

DenseNet121 ha ottenuto il risultato migliore sul terzo dataset, con un'accuratezza dell'80,52% e un'AUC-ROC pari a 0,81. In questo dataset la sensibilità era 0,80 e la specificità 0,81 mentre ResNet50 ha ottenuto le prestazioni migliori nel secondo dataset. [17]

È quindi necessario interpretare con cautela i confronti tra diversi articoli in quanto dataset, suddivisione delle immagini, preprocessing, bilanciamento delle architetture e strategie di validazione diverse possono influire molto sul risultato ottenuto.

Per questo motivo, il benchmarking dovrebbe utilizzare condizioni sperimentali e criteri di valutazione il più possibile simili.

Inoltre, nel contesto della diagnosi del melanoma, l'architettura ottimale non può essere identificata considerando esclusivamente l'accuratezza del modello, è necessario valutare contemporaneamente sensibilità, specificità, precisione, F1-score, AUC e complessità computazionale. [18]

1.2.4. Confronto con tecniche diagnostiche tradizionali

Attraverso l'analisi di 95 studi Yee et al. [19] hanno dimostrato che l'accuratezza diagnostica delle CNN e dell'intelligenza artificiale può essere superiore o almeno equivalente a quella dei clinici.

Il melanoma è una patologia ad alta variabilità visiva e la distinzione da lesioni benigne può essere difficile anche in dermoscopia.

Le CNN possono fornire un supporto oggettivo e riproducibile alla diagnosi riducendo la variabilità tra medici migliorare l'accuratezza diagnostica e supportando decisioni cliniche più affidabili.

Nei più recenti studi le CNN hanno mostrato la capacità di raggiungere livelli di accuratezza molto buoni come è facile notare dai seguenti dati:

nella diagnosi di melanoma ResNet50 raggiunge un'accuratezza pari a circa l'85% con baseline classica e ha raggiunto soglie dell'88,34% in uno studio condotto da Aryan Bhagat.[20]

In uno studio condotto da Faghihi et al. Vgg16 ha raggiunto un'accuratezza del 97,51% [21] mentre DenseNet121 ha raggiunto accuratezza del 92.30% in un altro studio svolto da Alzahrani et al. [22]

È importante notare che questi studi sono stati fatti attraverso condizioni di preprocessing, database e processi di addestramento differenti e non rappresentano quindi un risultato assoluto delle performance di queste architetture ma ne evidenziano le potenzialità nel supporto alla diagnosi.

1.2.5. Limiti del modello e necessità di futuri sviluppi

Nonostante i risultati promettenti esistono ancora diverse criticità nell'utilizzo delle CNN in ambito clinico:

- **Dataset shift:** un modello può ottenere risultati eccellenti se i dati test sono simili a quelli di addestramento ma può perdere accuratezza quando cambiano popolazione, qualità delle immagini o distribuzione delle patologie. I dataset utilizzati per il training spesso sono limitati e non sempre rappresentano la variabilità reale dei pazienti, fattore che può introdurre bias nelle predizioni. Acquisire e annotare immagini mediche sono attività costose e laboriose che richiedono la supervisione di specialisti;
- **Qualità delle immagini:** la presenza di artefatti nelle immagini date in input al modello come peli, segni di penna, bolle d'aria, variazioni di illuminazione e contrasto e la differente istituzione presso cui è stata acquisita l'immagine possono influire negativamente sulle prestazioni dei modelli;
- **Incapacità di riconoscere e segnalare condizioni fuori dal proprio ambito:** quando ad un modello viene presentata un'immagine riguardante una patologia non presente nei dati di train, il sistema non è capace di segnalarla e, al contrario, la classifica come una delle condizioni che ha imparato a riconoscere. Questo può generare biopsie non necessarie, aumento di falsi

positivi, ansia nel paziente e rischi di applicare il modello fuori dal proprio ambito di competenza;[23]

- **Modelli poco interpretabili:** le CNN, a causa della loro complessità strutturale, presentano una limitata interpretabilità in quanto le decisioni derivano da numerosi parametri appresi automaticamente e da relazioni complesse. Risulta ancora difficile capire su quale criterio il modello abbia preso una determinata decisione e se questo si sia basato su caratteristiche dermatologiche rilevanti oppure su correlazioni spurie presenti nei dataset di allenamento; [23], [24]
- **Overfitting:** un modello che funziona bene su un dataset può non farlo su dati clinici reali. [23]

Finché queste problematiche non saranno affrontate in modo affidabile, sebbene siano stati compiuti enormi progressi tecnici, permangono importanti carenze che devono essere affrontate prima dell'impiego clinico di questi algoritmi.

Risulta quindi fondamentale aumentare la trasparenza, riproducibilità e spiegabilità di questi strumenti affinché possano essere utilizzati in sicurezza come supporto decisionale degli specialisti.

La ricerca attuale si concentra in particolare su:

- **Tecniche di explainability AI** come Grad-CAM, occlusion maps, LIME, visualizzazione delle regioni maggiormente responsabili della predizione;
- **Miglioramento dei dati** attraverso tecniche di preprocessing, normalizzazione, riduzione del rumore e data augmentation;
- **Transfer learning** per sfruttare modelli pre-addestrati e ridurre la quantità di dati medici annotati necessaria per l'addestramento;
- **Creazione di modelli più robusti e generalizzati** validando su dataset esterni con popolazioni diverse e dati provenienti da più centri clinici.
- **Validazione in contesti clinici reali su larga scala.**[25]

1.3. Obiettivi del progetto

1. **Addestrare una CNN per classificare le immagini dermoscopiche tramite un classificatore binario: "lesioni cutanee benigne vs melanoma maligno".**
Verrà utilizzata la tecnica del transfer learning che utilizza architetture già esistenti congelandone i layer più profondi contenenti feature semplici già apprese da ImageNet dataset (riconoscimento di bordi, forme, colori). Questa

tecnica è particolarmente adatta in ambito medico per ridurre la quantità di immagini necessarie all'interno dei dataset.

2. Valutare le prestazioni di tre architetture: Vgg16, ResNet50 e DenseNet121.

Il confronto di questi tre modelli consente di valutare tre strategie architettureali differenti: una struttura convoluzionale sequenziale, una struttura basata su connessioni residue e una struttura basata su connessioni dense.

- a) Inizialmente i modelli verranno addestrati con una pipeline e con un dataset comune. Le prestazioni riportate in letteratura hanno mostrato che nessuna architettura è universalmente superiore alle altre e il confronto delle prestazioni effettuato nelle stesse condizioni sperimentali consente quindi di ridurre l'influenza delle differenze legate al dataset, al preprocessing e alla procedura di addestramento. [17], [18]
- b) Successivamente verrà svolta una seconda fase di ottimizzazione mirata per analizzare come un differente tipo di preprocessing delle immagini o una diversa procedura di addestramento possano influenzare le performance delle tre diverse architetture.

Si vogliono poi analizzare gli errori del modello per capire dove e perché il sistema può fallire per comprendere le difficoltà diagnostiche e identificare possibili miglioramenti.

La valutazione delle prestazioni verrà fatta tramite metriche adatte al problema medico come accuracy, sensitivity, specificity, AUC e confusion matrix.

3. Explainability delle architetture tramite Grad-CAM.

Questa fase si concentra nella creazione e analisi di mappe di attivazione che indicano le aree dell'immagine che maggiormente hanno influito nella decisione finale del modello. Si vuole verificare se il modello si focalizza sulla lesione o se, al contrario, presenta segnali di bias verso sfondo, bordi, peli, marker clinici. Questa fase è particolarmente rilevante in quanto in ambito medico risulta ancora difficile capire su quale criterio il modello abbia preso una determinata decisione e se si sia basato su aree dermatologicamente rilevanti della lesione.

2 Materiali e metodi

2.1. Dataset e Ambiente di lavoro

Tutti gli esperimenti sono stati realizzati utilizzando Tensorflow e Keras all'interno dell'ambiente di sviluppo Google Colab e sono stati scritti attraverso il linguaggio Python.

È stato utilizzato un dataset pubblico disponibile su Kaggle contenente immagini dermoscopiche appartenenti all'archivio ISIC e divisi in due classi: lesione benigna e melanoma maligno. [26]

Il dataset è suddiviso in due sottoinsiemi principali:

- Una cartella di train: contiene 2637 immagini che è stata utilizzata per addestramento e validazione.
- Una cartella di test: contiene 660 immagini ed è mantenuta separata dalla precedente ed utilizzata per la valutazione finale.

Le immagini vengono caricate automaticamente con etichette binarie inferite tramite la funzione:

```
tf.keras.utils.image_dataset_from_directory
```

Questa funzione genera un oggetto costituito da batch di immagini con le relative etichette. L'assegnazione numerica delle classi dipende dall'ordinamento delle sottocartelle nel dataset che risulta essere ['benign', 'malignant'], di conseguenza alla classe semantica 'benign' corrisponde l'etichetta numerica '0' mentre a 'malignant' viene assegnato '1'.

Il vantaggio di utilizzare un dataset pubblico consiste principalmente nell'evitare problemi burocratici legati a accesso di dati clinici reali per concentrarsi sull'analisi e sul modello.

È stata infine creata una repository pubblica su GitHub contenente tutti i codici e una cartella risultati di questo progetto. Nel file README sono contenute tutte le istruzioni per il suo utilizzo. [27]

2.2. Prima fase: confronto tra Vgg16, ResNet50 e DenseNet121 attraverso una baseline comparativa comune

La prima fase sperimentale è stata progettata per confrontare, attraverso una baseline comparativa comune, tre architetture di reti neurali convoluzionali: Vgg16, ResNet 50 e DenseNet121. Il codice completo di questa fase e di quelle successive è disponibile sul repository di GitHub. [27]

L'obiettivo non è ottimizzare i modelli ma definire una pipeline standard comune affinché il confronto delle prestazioni dipenda principalmente dalle tre architetture e non da differenti impostazioni di training.

2.2.1. Preprocessing: ridimensionamento, normalizzazione e data augmentation

Il preprocessing è fondamentale per migliorare la qualità del training e la capacità di generalizzare del modello.

- **Ridimensionamento:** le immagini sono state ridimensionate a 224x224 pixel su Kaggle, dimensione compatibile con il formato di input di norma utilizzato dai tre modelli pre-addestrati su ImageNet. Questo passaggio permette di utilizzare la medesima testa classificatoria e utilizzare immagini con dimensioni standard.
- **Normalizzazione:** i valori dei pixel sono stati trasformati nell'intervallo [0,1] mediante:
`normalization_layer = layers.Rescaling(1./255)`
 In questa fase è stata applicata una normalizzazione uniforme per tutti i modelli invece del preprocessing specifico previsto individualmente per ciascun modello Keras. Questa scelta permette un confronto più uniforme ma potrebbe anche rappresentare un limite sperimentale in quanto i pesi di ImageNet sono stati in origine calibrati tramite specifiche diverse in base ai modelli.
- **Data augmentation:** questa tecnica è stata applicata per diminuire il rischio di overfitting aumentando artificialmente la variabilità dei dati usati. È stata applicata all'intera cartella di train prima che venisse suddiviso in 'validation set' e 'training set'. Sono state impostate le seguenti trasformazioni: riflessione orizzontale (appropriata in quanto una lesione cutanea non necessariamente possiede un orientamento obbligatorio), rotazione casuale e zoom. Le ultime due sono particolarmente utili perché permettono al modello di concentrarsi

sulle caratteristiche della lesione invece che sulla posizione esatta all'interno dell'immagine. La funzione è così definita:

```
data_augmentation = keras.Sequential([
    layers.RandomFlip("horizontal"),
    layers.RandomRotation(0.2),
    layers.RandomZoom(0.1),])
```

- **Batch:** le immagini sono state suddivise in batch di 32 elementi, questo permette al modello di apprendere con approssimazioni più rumorose e meno precise riducendo il rischio di overfitting rispetto a batch più grandi.

2.2.2. Transfer learning

Il transfer learning consiste nell'utilizzare architetture esistenti con pesi preaddestrati su grandi dataset generici che hanno già imparato a riconoscere alcuni elementi semplici delle immagini come bordi, texture e forme. Nell'ambito medico risulta particolarmente utile in quanto i dataset disponibili sono di dimensioni limitate.

I tre modelli utilizzati in questo progetto fanno parte della famiglia Keras Application, la quale dispone di architetture predefinite utilizzabili per transef learning.

In questi esperimenti sono stati utilizzati pesi appresi sul dataset di ImageNet impostando l'opzione:

```
weights="imagenet"
```

Procedura di transfer learning implementata:

1. **Caricare le architetture preaddestrate.**
2. **Rimuovere il classificatore originale** tramite l'opzione:
include_top=False
3. **Congelare i layer della base convoluzionale** che permettono l'estrazione delle caratteristiche generiche dall'immagine. Questo passaggio è stato fatto tramite l'opzione:
base_model.trainable = False
4. **Aggiunta di una nuova testa classificatoria** in ogni modello, questa verrà poi addestrata per il problema specifico da affrontare. Tutte le architetture utilizzano la stessa testa classificatoria così definita:

```
x = layers.GlobalAveragePooling2D()(x)
x = layers.Dense(128, activation="relu")(x)
x = layers.Dropout(0.5)(x)
outputs = layers.Dense(1, activation="sigmoid")(x)
```

La scelta di utilizzare GlobalAveragePooling2D permette di limitare la complessità della testa aggiunta riducendo il numero di connessioni verso il classificatore finale.

`Layers.Dense(128, activation="relu")` consente di ottenere una rappresentazione più adatta alla distinzione tra lesioni benigne e maligne combinando le caratteristiche estratte dal backbone.

La funzione dropout è stata aggiunta per diminuire il rischio di overfitting riducendo la dipendenza del classificatore da correlazioni specifiche nel dataset attraverso lo spegnimento casuale del 50% delle attivazioni durante il training. L'output infine è stato impostato per fare una classificazione binaria e fornisce un valore compreso tra 0 e 1 che rappresenta la probabilità di appartenenza alla classe positiva (valori superiori a 0.5 vengono assegnati alla classe 1).

5. **Addestrare la nuova testa classificatoria** attraverso il dataset specifico del problema.

2.2.3. Training e validation

- È stata effettuata una suddivisione della cartella train in due sottogruppi: 80% delle immagini sono usate per il training e il 20% per la validation. Quest'ultimo viene utilizzato per verificare progressivamente la generalizzazione del modello e salvare il checkpoint migliore. La cartella di test rimane separata ed è stata usata solo per valutare le prestazioni finali post addestramento del modello.
- I tre modelli sono stati addestrati per dieci epoche tramite uno stesso ciclo for garantendo quindi condizioni omogenee:

```
for name in ["vgg16", "resnet", "densenet"]
```
- È stata utilizzata una funzione di perdita adatta al problema binario con un unico output sigmoide:

```
loss="binary_crossentropy"
```
- La metrica utilizzata per monitorare il training è l'accuracy che rappresenta la proporzione di predizioni corrette sul totale di campioni.
- È stato utilizzato l'ottimizzatore Adam tramite parametri predefiniti della versione TensorFlow/keras:

```
optimizer=keras.optimizers.Adam()
```
- Dopo ogni ciclo di training viene salvato unicamente il check point con il più basso valore di validation loss tramite la funzione:

```
ModelCheckpoint(
    filepath=checkpoint_path,
    monitor="val_loss",
```

```
save_best_only=True,
mode="min",
verbose=1)
```

- La storia delle metriche calcolate durante il training (loss, accuracy, val_loss, val_accuracy) viene salvata in file JSON e permette la ricostruzione delle curve di apprendimento anche dopo il riavvio del runtime di Google Colab.

2.2.4. Test

Al termine dell'addestramento viene caricato il migliore modello salvato di ogni architettura che viene valutato tramite il set test. Le metriche utilizzate per analizzare la capacità di generalizzare vengono raccolte in un file CSV mentre i grafici sono salvati in formato PNG.

Metriche utilizzate:

- **Accuracy:** proporzione totale di predizioni corrette.
- **Sensitivity:** capacità di riconoscere i casi di melanoma maligno.
- **Specificity:** capacità di riconoscere i casi benigni.
- **F1-score:** considera contemporaneamente la capacità di riconoscere i positivi e la precisione nelle predizioni positive.
- **AUC_ROC:** valuta la capacità discriminativa del modello su diverse soglie. Se il valore è prossimo a 1 il modello ha un'ottima capacità discriminativa mentre la soglia dello 0,5 indica un modello con classificazione casuale.
- **ROC_curve:** mostra il rapporto tra sensitivity e false positive rate ($FP/(FP+TN)$) e indica la capacità discriminativa del modello al variare della soglia di classificazione.
- **Confusion Matrix:** permette di analizzare visivamente il numero di predizioni corrette o errate divise per classe ed è strutturata come nella tabella 4.

Tabella 4. Struttura della matrice di confusione.

	Predizione benigna	Predizione maligna
Etichetta benigna	TN	FP
Reale maligna	FN	TP

Un falso positivo è una lesione benigna predetta dal modello come maligno mentre un falso negativo è un melanoma maligno classificato come benigno.

Nel contesto clinico considerato i falsi positivi sono maggiormente critici in quanto lasciano non diagnosticati dei casi patologici. Un modello con accuracy alta ma sensitivity bassa risulterebbe quindi non adatto alla diagnosi.

Il salvataggio separato di modelli, history, metriche e grafici consente di ricostruire l'andamento del training, confrontare le architetture, riutilizzare i modelli senza riaddestrarli, preservare i risultati anche dopo la chiusura del runtime Colab, migliorando la riproducibilità dell'esperimento.

2.2.5. Cross-Validation

Dopo aver verificato il corretto funzionamento della baseline e dell'implementazione delle tre architetture tramite una prima fase di training e test, è stata eseguita una cross-validation a 3 fold per migliorare la solidità statistica dei risultati. Per una stima più stabile delle prestazioni, in linea teorica, un numero maggiore di fold (ad esempio 5 o 10) sarebbe stato preferibile ma, per motivi pratici di tempo e risorse computazionali, si è scelto di limitarsi a 3 fold mantenendo comunque un protocollo metodologicamente corretto e riproducibile.

La cross-validation è stata applicata ai tre modelli mantenendo invariati i parametri e la struttura delle architetture rispetto alla baseline originale in modo che le differenze osservate fossero attribuibili principalmente alla variabilità del campionamento dei fold e non a modifiche architetturali.

Per ogni modello è stato suddiviso il dataset di training originale in tre fold. È stata utilizzata

StratifiedKFold con $k=3$, shuffle attivo e seed fissato.

Grazie alla stratificazione viene garantita approssimativamente la medesima proporzione di immagini maligne e benigne nei fold, aspetto fondamentale in contesti medici dove uno sbilanciamento numerico delle classi può influenzare molto le metriche di valutazione.

Per ciascun fold sono state utilizzate due parti per il training set e una per il validation set e sono poi stati addestrati tre modelli distinti (ottenendo complessivamente nove addestramenti distinti).

Il preprocessing è stato mantenuto invariato ma la data augmentation è stata applicata solamente al training set per ciascun fold. Questa scelta consente di ottenere valori di performance che non dipendono dalle trasformazioni casuali applicate rendendo più affidabile il confronto.

È stato inoltre introdotto il callback EarlyStopping per interrompere automaticamente il training nel caso in cui la validation loss non migliorasse per un numero consecutivo di epoche limitando il rischio di overfitting.

Le metriche di valutazione sono state calcolate per ogni fold sul validation set corrispondente e sono stati generati i grafici box plot comparativi con sovrapposti i singoli fold che permettono una visualizzazione delle variabilità tra le ripetizioni.

Per ogni fold sono stati salvati il miglior modello, la history del training (loss, accuracy, validation loss, validation accuracy), le metriche di valutazione sul validation fold, la matrice di confusione e la curva ROC corrispondenti.

Questo approccio consente di ricostruire, per ogni architettura, non solo le prestazioni medie, ma anche l'andamento del training, la variabilità tra i fold e la stabilità dei modelli al variare del campionamento del dataset.

2.3. Seconda fase: ottimizzazione

Dopo la prima fase sperimentale di baseline e di cross validation a 3 fold, sono state implementate tecniche di ottimizzazioni specifiche volte a migliorare le prestazioni dei modelli. L'obiettivo non è quello di cambiare radicalmente l'architettura ma introdurre modifiche mirate al tipo di preprocessing, regolazione e strategia di training mantenendo una struttura confrontabile con la prima fase.

A seguito dei risultati ottenuti dalla prima fase si è scelto di suddividere in due fasi distinte l'ottimizzazione:

- Ottimizzazione mirata per ResNet50;
- Ottimizzazione congiunta di Vgg16 e DenseNet121.

2.3.1. Ottimizzazione mirata di ResNet50

Nella prima fase ResNet50 ha mostrato prestazioni critiche e un fallimento nella capacità di predire correttamente i casi di melanoma. A seguito di questi risultati è risultata evidente la necessità di un adattamento più specifico del modello al dominio dermoscopico.

- **Preprocessing specifico:** contrariamente alla baseline in cui tutte le architetture hanno ricevuto immagini con il medesimo preprocessing, in questa fase è stata utilizzata la funzione `preprocess_input` come mostrato di seguito:

```
train_ds = train_ds.map(lambda x, y: (preprocess_input(x), y))
test_ds = test_ds.map(lambda x, y: (preprocess_input(x), y))
```

In questo modo alle immagini vengono applicate le trasformazioni previste da Keras con cui i pesi di ResNet50 sono stati addestrati sul dataset di ImageNet. Questa funzione permette di sfruttare meglio i pesi pre-addestrati e rende il trasferimento delle features da ImageNet al dominio dermoscopico maggiormente coerente con le condizioni originali di training del modello.

- **Fine-tuning parziale del backbone:** in questa seconda fase gli strati più profondi della rete (30 layers) non sono più congelati ma vengono resi addestrabili per permettere al modello di specializzarsi maggiormente nel dominio specifico delle immagini dermoscopiche e meno sulle rappresentazioni apprese originariamente del dataset Imagenet. I primi (n-30) layer del modello rimangono invece congelati consentendo di continuare ad utilizzare le feature generiche precedentemente apprese. Questa opzione è stata così implementata:

```
base_model.trainable = True
for layer in base_model.layers[:-30]:
    layer.trainable = False
```
- **Riduzione del learning rate:** Diminuire il learning rate dell'algoritmo di Adam permette di aggiornare i pesi degli ultimi layer allenabili in modo più graduale ed è utile per evitare di perdere le feature di ResNet50 apprese da ImageNet durante il pre-training:

```
optimizer=keras.optimizers.Adam(learning_rate=1e-4)
```
- **Early stopping e ModelCheckpoint:** La funzione di early stopping che interrompe il training e ripristina i pesi migliori se la validation loss non migliora per 3 epoche consecutive è stata introdotta direttamente nella pipeline e non solo durante la Cross validation come nel caso della prima fase. Questo callback, in combinazione con ModelCheckpoint, riduce il rischio di scegliere come modello finale uno in fase di overfitting.

2.3.2. Ottimizzazione congiunta di Vgg16 e DenseNet121

Nella prima fase sperimentale Vgg16 e DenseNet121, al contrario di ResNet50, hanno mostrato buone capacità discriminative di casi benigni e maligni. A seguito di questi risultati si è scelto, nella seconda fase, di ottimizzare i due modelli congiuntamente con l'obiettivo di migliorarne ulteriormente la stabilità del training e la generalizzazione senza tuttavia alterare la struttura di base delle architetture.

- **Preprocessing:** contrariamente a ResNet50 ottimizzato, non è stato applicato il ridimensionamento specifico dei singoli modelli ma si è scelto di mantenere il preprocessing originale applicato nella baseline comune. Questo garantisce maggiore conformità con la prima fase e tra le due architetture ottimizzate.
- **Aumento dell'intensità della data augmentation:** l'intensità dello zoom casuale è stata aumentata a 0.2 per introdurre maggiore variabilità geometrica

nelle immagini di training. Questa scelta favorisce una migliore capacità di generalizzare del modello a variazione di posizione e ingrandimento relativo della lesione nell'immagine. Per coerenza con il dominio medico del problema si è scelto di non utilizzare tecniche di data augmentation che modificassero il contrasto o i colori dell'immagine al fine di non perdere informazioni preziose per la diagnosi.

- **Regolarizzazione dei pesi L2:** nel Dense Layer da 128 neuroni della testa classificatoria è stata introdotta la regolarizzazione dei pesi L2 come di seguito illustrato:

```
x = layers.Dense(128, activation="relu", kernel_regularizer=l2(0.001))(x)
```

Questa opzione aggiunge alla funzione `loss_val` un costo associato a pesi elevati in modulo per rendere il modello più semplice e contribuendo a limitare l'overfitting soprattutto nei casi in cui il dataset di training è limitato come nei casi clinici.

- **Batch normalization:** Dopo il layer Dense è stata aggiunta una batch normalization che migliora la convergenza e riduce la sensibilità alla scelta del learning rate stabilizzando la distribuzione delle attivazioni durante il training:

```
x = layers.BatchNormalization()(x)
```

Contribuisce quindi a rendere il training meno soggetto alle oscillazioni dei gradienti.

- **Aumento del Dropout:** Il dropout dei modelli durante il training è stato aumentato da 0.5 a 0.6 favorendo una migliore generalizzazione.
- **EarlyStopping, ReduceLROnPlateau e ModelCheckpoint:** La funzione EarlyStopping è stata introdotta con '*pazienza*' pari a cinque epoche.

È stata inoltre implementata una funzione ReduceLROnPlateau che, quando la `val_loss` smette di imparare, riduce il learning rate:

```
reduce_lr = ReduceLROnPlateau(
    monitor="val_loss",
    factor=0.5,
    patience=2,
    min_lr=1e-6 )
```

Queste due callback, in combinazione con ModelCheckpoint, permettono di interrompere il training al momento opportuno, ridurre il learning rate automaticamente per perfezionare la convergenza e conservare il modello con val_loss migliore tra quelle osservate.

2.3.3. Cross-validation

Dopo la verifica del corretto funzionamento e implementazione delle architetture ottimizzate, è stata effettuata per ogni modello ottimizzato una cross validation a 3 fold con metodologia analoga a quella della prima fase sperimentale.

2.4. Explainability con Grad-CAM

Per completare l'analisi quantitativa delle prestazioni è stata condotta un'analisi di explainability mediante Gradient-weighted Class Activation Mapping (Grad-CAM). Grad-CAM è una tecnica di interpretabilità post-hoc per reti convoluzionali, produce una mappa di calore delle regioni dell'immagine che contribuiscono maggiormente alla predizione di una specifica classe. Vengono usati i gradienti dell'output di interesse rispetto alle feature map dell'ultimo layer convoluzionale ottenendo una localizzazione visiva delle aree più influenti nella decisione del modello.

Le predizioni sono state associate agli esiti TP, TN, FP e FN confrontando la classe stimata con l'etichetta reale per permetter di confrontare le mappe Grad-CAM non soltanto tra architetture, ma anche in relazione alla correttezza o all'errore della predizione.

L'analisi è stata applicata ai modelli Vgg16, ResNet50 e DenseNet12 corrispondenti alla prima esecuzione di training, cioè prima della successiva procedura di cross-validation, sia per la prima che per la seconda fase.

L'obiettivo dell'analisi non era stimare nuovamente le prestazioni globali ma osservare qualitativamente quali regioni delle immagini venissero valorizzate dai diversi modelli nel processo decisionale.

Le aree a maggiore attivazione sono rappresentate con colori più caldi, mentre i colori più freddi indicano una minore influenza positiva sull'output di malignità.

Per ciascun modello sono state selezionate le prime dieci immagini, in ordine alfabetico di filename contenute nelle cartelle benign e malignant del test set. L'analisi ha quindi considerato in totale 20 immagini per architettura, per un totale di 60 visualizzazioni nella prima fase e altre 60 in quella ottimizzata.

Per i modelli della **prima fase sperimentale** per applicare Grad-CAM è stato necessario costruire una versione "flat" di ciascun modello, con input esplicito e nomi identificabili per i layer della testa classificatoria. I pesi della testa addestrata sono stati

copiati nel modello destinato all'analisi dopo aver verificato la compatibilità dimensionale dei pesi dei layer Dense e di output. Questa procedura consente di ricostruire una struttura del modello accessibile per l'estrazione delle feature map e il calcolo dei gradienti, senza modificare la testa classificatoria appresa.

Le mappe Grad-CAM sono state calcolate a partire dall'ultimo layer convoluzionale di ogni architettura che conserva l'informazione spaziale e rappresenta anche feature di alto livello collegate alla predizione finale:

- Vgg16: block5_conv3
- ResNet50: conv5_block3_out
- DenseNet121: conv5_block16_2_conv

Per ciascuna immagine sono stati prodotti e salvati quattro output: l'immagine originale, l'heatmap Grad-CAM, l'overlay tra immagine e heatmap (generato combinando l'immagine originale con la mappa colorata mediante un coefficiente di trasparenza $\alpha = 0,4$.) e il pannello comparativo contenente le tre visualizzazioni.

I risultati sono stati organizzati in sottocartelle per modello, esito e classe reale e sono stati salvati in file CSV.

L'analisi Grad-CAM è stata successivamente estesa alle **versioni ottimizzate** dei modelli. Per Vgg16 e DenseNet121 è stata adottata una procedura analoga alla versione standard, ricostruendo una testa classificatoria coerente con la nuova configurazione. Per ResNet50 ottimizzata, il modello salvato è stato invece caricato direttamente in quanto la sua architettura salvata, per differenze di implementazione rispetto alle altre due, consentiva di accedere esplicitamente alla backbone, all'ultimo layer convoluzionale conv5_block3_out e ai layer della testa classificatoria.

Anche per i modelli della seconda fase sono state utilizzate dieci immagini benigne e dieci maligne del test set e gli stessi criteri di salvataggio della prima fase.

3 Risultati

3.1. Prima fase: baseline comune

Tabella 5. Valori delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.

model	fold	accuracy	sensitivity	specificity	F1	auc
Vgg16	1	0.8123	0.8496	0.7812	0.8043	0.9015
Vgg16	2	0.8259	0.8972	0.7667	0.8239	0.9002
Vgg16	3	0.8077	0.8596	0.7646	0.8023	0.8978
ResNet50	1	0.5461	0.0000	1.0000	0.0000	0.8078
ResNet50	2	0.5472	0.0075	0.9958	0.0149	0.7267
ResNet50	3	0.5461	0.0025	0.9979	0.0050	0.7878
DenseNet121	1	0.8567	0.8596	0.8542	0.8448	0.9439
DenseNet121	2	0.8487	0.8471	0.8500	0.8356	0.9354
DenseNet121	3	0.8385	0.8296	0.8458	0.8234	0.9296

I risultati dei tre fold delle cross-validation sono stati sintetizzati come media delle metriche dei tre fold con finalità descrittiva e comparativa ma non è da intendersi come dimostrazione statistica della superiorità di un modello rispetto ad un altro. Si è scelto di non utilizzare un'analisi inferenziale formale basata su test statistici o intervalli di confidenza in quanto per k=3 fold la stima della deviazione standard risulterebbe


molto instabile e la solidità statistica sarebbe di difficile interpretazione per un numero basso di osservazioni.

Tabella 6. Valori delle medie delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.


model	accuracy	sensitivity	specificity	f1	auc
Vgg16	0.8153	0.8688	0.7708	0.8102	0.8998
ResNet50	0.5465	0.0033	0.9979	0.0066	0.7741
Densenet121	0.8479	0.8454	0.8500	0.8346	0.9363

Figura 1. Grafico delle medie delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.


1.a. Accuracy



1.b. Sensitivity



1.c. Specificity



3.1.1. Boxplot

Per facilitare la comprensione visiva dei risultati e della variabilità dei fold e dei modelli sono stati generati dei box plot in cui sono mostrati i valori dei singoli fold e una deviazione standard comparativa.

Figura 2. Boxplot dell'accuracy data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.




Figura 3. Boxplot della sensitivity data dalla cross-validation a 3 fold di Vgg16, Resnet50 e DenseNet121 nella prima fase sperimentale.




Figura 4. Boxplot della specificity data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.




Figura 5. Boxplot della AUC data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.






Figura 6. Boxplot della F1 score data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.




3.1.2. Confusion matrix

Figura 7. Confusion-matrix dei 3 fold di Vgg16 nella prima fase sperimentale.

7.a. fold 1



7.b. fold 2



7.c. fold 3




Figura 8. Confusion-matrix dei 3 fold di ResNet50 nella prima fase sperimentale.





Figura 9. Confusion-matrix dei 3 fold di DenseNet121 nella prima fase sperimentale.



3.1.3. Roc-curve prima fase

Figura 10. Roc-Curve dei 3 fold di Vgg16 nella prima fase sperimentale.




Figura 11. Roc-Curve dei 3 fold di ResNet50 nella prima fase sperimentale.





Figura 12. Roc-Curve dei 3 fold di DenseNet50 nella prima fase sperimentale.



3.2. Seconda fase: ottimizzazione

Tabella 7. Valori delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda fase sperimentale di ottimizzazione.

model	fold	accuracy	sensitivity	specificity	f1	auc
vgg16	1	0.8134	0.7118	0.8979	0.7760	0.9106
vgg16	2	0.8350	0.8947	0.7854	0.8312	0.9103
vgg16	3	0.8248	0.8772	0.7812	0.8197	0.9118
ResNet50	1	0.8521	0.8797	0.8292	0.8438	0.9371
ResNet50	2	0.8919	0.8947	0.8896	0.8826	0.9568
ResNet50	3	0.8919	0.9173	0.8708	0.8851	0.9608
DenseNet121	1	0.8589	0.8145	0.8958	0.8398	0.9415
DenseNet121	2	0.8635	0.8772	0.8521	0.8537	0.9345
DenseNet121	3	0.8544	0.8997	0.8167	0.8487	0.9332


Tabella 8. Valori delle medie metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda fase sperimentale di ottimizzazione.

model	accuracy	sensitivity	specificity	f1	auc
vgg16	0.8244	0.8279	0.8215	0.8089	0.9109

model	accuracy	sensitivity	specificity	f1	auc
DenseNet121	0.8589	0.8638	0.8549	0.8474	0.9364
ResNet50	0.8786	0.8972	0.8632	0.8705	0.9516

Figura 13. Grafico delle medie delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, Resnet50 e DenseNet121 nella seconda fase sperimentale.


13.a. Accuracy



13.b. Sensitivity



13.c. Specificity



3.2.1. Boxplot

Figura 14. Boxplot dell'accuracy data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda sperimentale.




Figura 15. Boxplot della sensitivity data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda fase sperimentale.




Figura 16. Boxplot della specificity data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda sperimentale.




Figura 17. Boxplot della AUC data dalla cross-validation a 3 fold di Vgg16, Resnet50 e DenseNet121 nella seconda fase sperimentale.





Figura 18. Boxplot della F1 score data dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda fase sperimentale.



3.2.2. Confusion matrix

Figura 19. Confusion-matrix dei 3 fold di Vgg16 nella seconda fase sperimentale.






Figura 20. Confusion-matrix dei 3 fold di ResNet50 nella seconda fase sperimentale.**Figura 21.** Confusion-matrix dei 3 fold di DenseNet121 nella seconda fase sperimentale.

3.3. Grad-CAM

Vengono qui riportate le griglie comparative delle heat-map prodotte con la tecnica grad-CAM delle prime tre lesioni benigne e tre maligne dei tre modelli ottenute durante la prima fase sperimentale e a seguito dell'ottimizzazione. La totalità delle mappe prodotte può essere trovata nella cartella Grad-CAM dedicata su GitHub. [27]

Figura 22. Heat-map comparativa delle prime tre lesioni benigne ottenute dai modelli Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.




Figura 23. Heat-map comparativa delle prime tre lesioni maligne ottenute dai modelli Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.




Figura 24. Heat-map comparativa delle prime tre lesioni benigne ottenute dai modelli Vgg16 e DenseNet121 nella seconda fase sperimentale.




Figura 25. Heat-map comparativa delle prime tre lesioni benigne ottenute da ResNet50 nella seconda fase sperimentale.




Figura 26. Heat-map comparativa delle prime tre lesioni maligne ottenute dai modelli Vgg16 e DenseNet121 nella seconda fase sperimentale





Figura 27. Heat-map comparativa delle prime tre lesioni maligne ottenute da ResNet50 nella seconda fase sperimentale.



4 Discussione

4.1. Prima fase

La prima fase sperimentale ha permesso di confrontare Vgg16, Resnet50 e DenseNet121 attraverso una cross-validation a 3 fold in cui, per ciascun fold, i modelli sono stati addestrati su due partizioni e valutati sulla terza parte del dataset. I risultati ottenuti da questa prima baseline comune hanno mostrato differenze sostanziali tra i diversi modelli. Vgg16 e DenseNet121 hanno mostrato un comportamento generalmente più stabile e affidabile di ResNet50, il quale evidenzia un fallimento marcato nella capacità di riconoscere la classe melanoma.

4.1.1. Vgg16

Vgg16 ha raggiunto un'accuracy media nei 3 fold di 0,8153 e un'AUC media di 0,8998. La sensitivity media è risultata di 0,8688, superiore quindi alla specificity, pari a 0,7708.

Questi dati mostrano che il modello ha sviluppato una maggiore capacità di distinguere correttamente casi maligni rispetto ai benigni. In generale nell'ambito specifico di melanoma è preferibile avere una sensibilità più accurata rispetto alla specificità in quanto è più rischioso non riconoscere una lesione maligna rispetto a classificare come melanoma una lesione benigna. Nonostante ciò, una minore specificità indica che il modello tende a classificare come sospette anche alcune lesioni benigne.

Il modello inoltre ha dimostrato un comportamento abbastanza stabile rispetto alle diverse partizioni del dataset in quanto le oscillazioni dei valori ottenuti nei diversi fold sono limitate: l'accuracy varia da 0,8077 a 0,8259 mentre la sensitivity da 0,8496 a 0,8972. Questo comportamento è visivamente osservabile anche nei boxplot della figura 2. per l'accuracy e figura 3. per la sensitivity in cui sono rappresentati nel grafico i valori delle metriche di ciascun fold (F1, F2, F3).

4.1.2. ResNet 50

ResNet50 in questa prima fase presenta dei risultati critici, come è facile notare visivamente anche dai grafici della figura 1. Sebbene la specificità media del modello risulti essere molto elevata pari a 0,9979, la sensibilità media è stata di 0,0033. Questo contrasto è spiegato dalla matrice di confusione nella figura 8. in cui si nota che il modello tende a classificare la quasi totalità dei campioni come benigni: la specificity nei tre fold è stata 1,0000, 0,9958 e 0,9979 mentre la capacità discriminativa dei maligni è quasi nulla con sensitivity è risultata rispettivamente di 0,0000, 0,0075 e 0,0025.

A seguito di questi risultati è facile capire perché l'accuratezza media di 0,5465 non può da sola essere indicatrice delle performance di un modello. In ambito medico questa metrica considerata da sola può essere fuorviante.

La F1-score media risulta anch'essa quasi nulla pari a 0,0066 mentre l'AUC media è di 0,7741. La spiegazione di questo sbilanciamento si trova nel fatto che l'AUC viene calcolata sulle probabilità continue e non sulle classi ottenute. Un modello può possedere una certa capacità di ordinare i campioni maligni al di sopra di quelli benigni, pur non producendo probabilità superiori a 0,5 in misura sufficiente per ottenere predizioni positive.

Tra le possibili cause del comportamento critico di Resnet50 vi sono:

- Preprocessing non del tutto coerente con quello utilizzato originariamente per il pretraining di ResNet50 su ImageNet;
- Lo sbilanciamento del numero di campioni tra le classi nel dataset potrebbe aver indotto il modello a predire la quasi totalità dei casi come una classe al posto che un'altra perché questa strategia permetteva di minimizzare la `val_loss` in quanto le lesioni beigne erano maggiori delle maligne. Così facendo il modello non ha imparato a generalizzare rispetto alle reali caratteristiche dermoscopiche del problema. Non sarebbe però corretto attribuire il comportamento critico del modello solamente al dataset in quanto la distribuzione non era estremamente sbilanciata: questa è vicina a 480 campioni benigni e 399 maligni per validation fold;
- Il freezing completo della rete ad eccezione del layer di testa potrebbe non aver consentito a ResNet50 di adattarsi adeguatamente al problema specifico. La presenza di skip connection rende infatti ResNet efficace per l'addestramento di reti profonde ma non garantisce automaticamente buone prestazioni quando la backbone viene utilizzata come estrattore congelato in un dominio diverso da ImageNet.

L'elevata specificity con sensitivity e F1-score quasi nulle indicano che il classificatore tende a generare previsioni negative indipendentemente dall'immagine.

Un falso negativo corrisponde infatti a una lesione potenzialmente maligna classificata come benigna. In base a questo criterio, nella prima fase sperimentale, VGG16 e DenseNet121 sono risultati nettamente più adeguati di ResNet50.

4.1.3. DenseNet121

Nella prima fase DenseNet121 ha ottenuto i migliori risultati rispetto agli altri modelli per accuracy, F1-score e AUC i cui valori medi dei 3 fold risultano essere rispettivamente 0,8479 , 0,8346 e 0,9363. La sensitivity media di 0,8454 è globalmente vicina alla specificity media pari a 0,8500. DenseNet mantiene quindi prestazioni simili sia nella capacità di riconoscere lesioni maligne che benigne. Questo equilibrio rappresenta uno dei principali punti di forza del modello.

Come si può notare anche dalle rappresentazioni nei boxplot i valori ottenuti dalle metriche dei diversi fold risultano abbastanza omogenei con l'accuracy varia tra 0,8385 e 0,8567 e sensitivity tra 0.8296 e 0.8596.

Il comportamento mostrato dal modello è inoltre compatibile con la sua struttura che favorisce il riutilizzo delle feature ottenute e prodotte nei layer precedenti.

4.2. Seconda fase: ottimizzazione

Durante la seconda fase sono state introdotte modifiche mirate alla pipeline dei modelli, questo ha portato variazioni nei valori delle metriche risultanti.

4.2.1. Vgg16

Vgg16 mostra un miglioramento dell'accuracy da 0,8153 a 0,8244 , dell'AUC da 0,8998 a 0,9109 e della specificity da 0,7708 a 0,8215. La sensitivity diminuisce invece da 0,8688 a 0,8279 e l'F1-score passa da 0,8102 a 0,8089 (variazione minima).

Questi valori mostrano che i cambiamenti introdotti nel modello nella seconda fase abbiano prodotto un comportamento più equilibrato tra le classi aumentando la capacità di riconoscere i campioni benigni diminuendo leggermente quella di individuare i maligni.

L'ottimizzazione ha migliorato accuracy, specificity e AUC, ma ha ridotto sensitivity e F1-score. La valutazione deve quindi dipendere dalla priorità applicativa: se l'obiettivo principale è evitare falsi negativi, il valore di sensitivity della baseline era superiore mentre se si desidera un compromesso più bilanciato, la seconda configurazione ottimizzata è più equilibrata.

L'aumento della specificity è coerente con l'effetto atteso delle tecniche di regolarizzazione e della maggiore augmentation: il modello potrebbe aver ridotto alcune predizioni positive eccessive.

4.2.2. Resnet50

Resnet50 ha mostrato il miglioramento delle performance più marcato. La sensibilità media è aumentata da 0,0033 a 0,8972 e la specificità media è diminuita da 0,9979 a 0,8632. Questi valori indicano una maggiore capacità di generalizzazione del modello rispetto alla prima fase. Il modello è passato da un comportamento quasi esclusivamente orientato alla classe benigna a un comportamento capace di riconoscere la maggior parte dei casi maligni. L'elevata specificità ottenuta nella prima fase non rappresentava nella realtà una buona capacità diagnostica, dopo l'ottimizzazione il valore medio di questa metrica è diminuito ma il modello ha raggiunto un equilibrio più utile tra sensibilità e specificità.

Il miglioramento è compatibile con le modifiche introdotte: il preprocessing specifico avvicina gli input alle condizioni previste dai pesi ImageNet, il fine-tuning degli ultimi 30 layer permette alla rete di adattare parte delle feature al dominio dermoscopico e il learning rate a 10^{-4} riduce l'ampiezza degli aggiornamenti dei pesi. Il miglioramento osservato può essere attribuito alla configurazione ottimizzata nel suo complesso, non esclusivamente al preprocessing o al fine-tuning in quanto non è possibile isolare l'effetto individuale di ciascuna modifica.

Per quanto riguarda le altre metriche, l'accuratezza media di Resnet50 ottimizzato di 0,8786, l'F1 score di 0,8705 e l'AUC di 0,9516 rappresentano le più alte ottenute tra i tre modelli testati sia nella prima che nella seconda fase.

4.2.3. DenseNet121

Rispetto a Vgg16, DenseNet121 ha dimostrato un miglioramento complessivo uniforme ma poco marcato rispetto alla precedente versione. L'accuracy passa da 0,8479 a 0,8589 e la sensitivity da 0,8454 a 0,8638. La specificity da 0,8500 a 0,8549 e F1-score da 0,8346 a 0,8474. Infine, l'AUC da 0,9363 a 0,9364 variazione che risulta trascurabile. Le variazioni dei valori medi delle metriche risultano essere minime rispetto a quelle ottenute da ResNet50 a seguito dell'ottimizzazione. Questo indica che DenseNet121 possedeva già una buona capacità discriminativa nella baseline e che le tecniche aggiunte hanno agito principalmente sulla stabilità della classificazione alla soglia 0,5.

4.3. Grad-CAM

Attraverso il confronto delle mappe Grad-CAM è stato possibile osservare i differenti modi in cui Vgg16, ResNet50 e DenseNet121 distribuivano l'attenzione sull'immagine permettendo di capire se la CNN stesse osservando la lesione oppure se il modello presentasse bias verso elementi non rilevanti come sfondo, bordi o artefatti. In un contesto medico questo passaggio è fondamentale in quanto in un modello buoni valori delle metriche non sono sufficienti da soli a garantire validità e coerenza con il problema clinico.

Il modello maggiormente interessante è ResNet50. Tramite Grad-CAM è stato possibile osservare che nella prima fase il collasso nelle metriche era coerente con le heat map che mostravano un'attenzione focalizzata in un punto tendenzialmente fisso per tutte le immagini. Le mappe erano quindi più povere e poco specifiche e coerenti rispetto ai differenti tipi di lesione.

A seguito dell'ottimizzazione ResNet50 non ha migliorato solamente i valori numerici delle metriche ma anche la sua coerenza visiva. Le nuove mappe Grad-CAM risultano più ricche, meno ripetitive e più compatibili con una reale capacità del modello di distinguere la regione patologica.

Se un modello migliora nelle metriche ma continua a guardare regioni non plausibili, la fiducia nel sistema resta limitata. Se invece migliorano sia le metriche sia le heatmap, allora la predizione è più solida, soprattutto in ambito medico, dove interpretabilità e affidabilità hanno un ruolo fondamentale.

Di conseguenza il miglioramento dell'explainability in ResNet50 è un risultato particolarmente rilevante perchè permette di affermare che la nuova pipeline non ha solo migliorato l'accuracy o l'AUC ma ha migliorato anche la qualità dell'attenzione del modello e la sua affidabilità clinica. Il miglioramento è quindi stato sia quantitativo che qualitativo.

DenseNet121 mostra in entrambe le fasi mappe spesso plausibili e ben concentrate e coerenti con la lesione. Di conseguenza il modello appare abbastanza coerente non solo dal punto di vista delle metriche ma anche dal punto di vista interpretativo.

Vgg16 appare invece generalmente più diffuso e meno localizzato rispetto all'area specifica della lesione all'interno dell'immagine ma comunque spesso segue aree visive plausibili.

Nella figura 23, la prima lesione maligna è stata classificata correttamente sia da Vgg16 che da DenseNet121 e dalle mappe di attivazione è facile osservare come le aree maggiormente osservate dai due modelli siano differenti. Vgg16 tende ad avere un'attenzione più diffusa mentre DenseNet121 mostra spesso un focus più compatto o più selettivo. Questo non significa automaticamente che uno sia sempre migliore dell'altro, ma aiuta a capire che architetture diverse costruiscono la decisione con strategie visive differenti e modelli diversi possono arrivare a una classificazione corretta osservando l'immagine anche in modo leggermente diverso.

Per concludere si può affermare che DenseNet121 tende a produrre mappe plausibili e spesso ben coerenti con la lesione, Vgg16 appare più diffuso e meno focalizzato. ResNet50 nella fase iniziale ha mostrato attenzione su regioni poco informative e coerenti mentre, a seguito dell'ottimizzazione, ha mostrato mappe più ricche, meno ripetitive e più compatibili con un'effettiva separazione tra benigno e maligno, coerentemente con il miglioramento quantitativo.

Questa correlazione tra metrica ed explainability è uno dei risultati più rilevanti dell'intero studio. Se un modello migliora in AUC e sensitivity ma continua a guardare sfondo o artefatti, la fiducia clinica resta limitata, se invece migliorano sia le metriche sia la plausibilità delle heatmap, l'interpretazione diventa molto più solida.

5 Conclusione

In conclusione, le CNN sono strumenti promettenti per la classificazione dermoscópica del melanoma ma il loro rendimento in quest'ambito non dipende solo dalla fama dell'architettura ma dal rapporto tra backbone, preprocessing, ottimizzazione e capacità di adattamento al dominio medico. In medical imaging non basta quindi avere una CNN preaddestrata e metriche alte, è necessario verificare se il modello generalizza davvero, se riconosce correttamente la classe clinicamente rilevante, e soprattutto se guarda regioni dell'immagine coerenti con il problema medico analizzato. In questo progetto la valutazione quantitativa e l'explainability sono state quindi considerate insieme e Grad-CAM risulta essere una parte essenziale del lavoro per capire se il modello prende decisioni in modo clinicamente plausibile.

Nella baseline, DenseNet121 ha mostrato il comportamento complessivamente migliore tra le tre architetture con accuracy media pari a 0,8479, F1-score pari a 0,8346 e AUC pari a 0,9363. Vgg16 ha raggiunto una sensitivity più elevata, pari a 0,8688, ma una specificity inferiore, pari a 0,7708. ResNet50 ha mostrato una forte tendenza a classificare tutti i campioni come benigni, con sensitivity media pari a 0,0033 e F1-score pari a 0,0066 mostrando quindi prestazioni critiche nella capacità di classificazione delle lesioni cutanee.

Per quanto riguarda l'explainability le mappe di attivazione si sono mostrate clinicamente plausibili per Vgg16 e DenseNet121 ma poco coerenti con la lesione e aspecifiche per ResNet50, risultati coerenti con le metriche valutate.

La fase di ottimizzazione ha prodotto il miglioramento più marcato per ResNet50 in cui l'introduzione del preprocessing specifico, del fine-tuning parziale degli ultimi 30 layer, del learning rate ridotto e dei callback di controllo ha portato l'accuracy a 0,8786, la sensitivity a 0,8972, l'F1-score a 0,8705 e l'AUC a 0,9516. La specificità è diminuita rispetto alla baseline, ma il modello ha perso il comportamento degenerato che lo portava a classificare quasi tutti i campioni come benigni migliorando molto le sue prestazioni complessive. Le mappe di attivazione di ResNet50 ottimizzato hanno mostrato sostanziali miglioramenti nella capacità di analizzare le aree rilevanti delle immagini e hanno aumentato la coerenza e la specificità rispetto alla prima fase sperimentale. Questi risultati suggeriscono che l'adattamento parziale del backbone e l'utilizzo del preprocessing coerente con ImageNet siano stati particolarmente importanti nel caso di questo modello.

DenseNet121 ha beneficiato dell'ottimizzazione con lievi miglioramenti in accuracy, sensitivity, specificity e F1-score, mantenendo un'AUC sostanzialmente invariata.

Vgg16 ha mostrato un miglioramento dell'accuracy, della specificity e dell'AUC ma una lieve riduzione della sensitivity e dell'F1-score.

Nel complesso, nella configurazione ottimizzata ResNet50 ha ottenuto i valori medi più elevati per accuracy, sensitivity, F1-score e AUC, mentre DenseNet121 ha mantenuto un comportamento molto solido e bilanciato. Vgg16 è risultata una baseline robusta.

ResNet50 rappresenta il caso più istruttivo: inizialmente fallisce in modo clinicamente critico, ma dopo ottimizzazioni mirate ottiene metriche e mappe di attivazione molto performanti anche rispetto alle altre due architetture.

Non è tuttavia possibile affermare una superiorità statisticamente significativa di un modello sugli altri, è più corretto concludere che, nelle condizioni sperimentali adottate, la configurazione ottimizzata di ResNet50 ha mostrato il miglior risultato medio, mentre DenseNet121 ha rappresentato la soluzione più stabile già nella baseline. Le tre architetture hanno mostrato comportamenti diversi. La pipeline, il preprocessing e l'ottimizzazione sono fattori che influenzano in modo decisivo l'adattamento al dominio medico e le prestazioni dei modelli.

In prospettiva di sviluppi futuri sarebbe possibile estendere la procedura di cross-validation a 5 o 10 fold per affinare ulteriormente la stima delle prestazioni medie e della loro variabilità. Sarebbe inoltre possibile addestrare i modelli su dataset più grandi e testarli esternamente in ambienti clinici. Infine, per migliorare ultimamente la pipeline e la precisione delle architetture si potrebbe integrare YOLO, un algoritmo di rilevamento oggetti.

Bibliografia

- [1] A. Dascalu, B. N. Walker, Y. Oron, e E. O. David, «Non-melanoma skin cancer diagnosis: a comparison between dermoscopic and smartphone images by unified visual and sonification deep learning algorithms», *J. Cancer Res. Clin. Oncol.*, vol. 148, fasc. 9, pp. 2497–2505, set. 2022, doi: 10.1007/s00432-021-03809-x.
- [2] J. C. Hwang, B. L. Peacker, e R. I. Hartman, «Screening and novel diagnostic technologies for melanoma: an update», *Melanoma Manag.*, vol. 12, fasc. 1, p. 2536999, lug. 2025, doi: 10.1080/20450885.2025.2536999.
- [3] S. Górecki, A. Tatka, e J. Brusey, «Artificial Intelligence and New Technologies in Melanoma Diagnosis: A Narrative Review», *Cancers*, vol. 17, fasc. 24, p. 3896, 2025, doi: 10.3390/cancers17243896.
- [4] H. Wang, H. Zhang, Y. Zhou, C. Li, e W. Guo, «Life Factors and Melanoma: From the Macroscopic State to the Molecular Mechanism», *Adv. Sci.*, vol. 12, fasc. 43, p. e01388, nov. 2025, doi: 10.1002/advs.202501388.
- [5] H. Qasim, M. A. Shugaer, K. Khattab, M. L. G. Leoni, e G. Varrassi, «Histopathological subtypes of cutaneous melanoma: prognostic and molecular implications», *Cureus*, vol. 17, fasc. 8, 2025.
- [6] M. S. Block, A. E. Stenzel, R. Marcotte, e K. L. Wallace, «Real-World Treatment Patterns in Advanced Cutaneous Melanoma in the USA», *Target. Oncol.*, vol. 21, fasc. 4, pp. 569–580, lug. 2026, doi: 10.1007/s11523-026-01235-y.
- [7] N. Cirillo, «Global epidemiological trends in the incidence and mortality for melanoma», *Skin Health Dis.*, vol. 5, fasc. 1, pp. 84–86, feb. 2025, doi: 10.1093/skinhd/vzae013.
- [8] K. Englert, A. Kłosowicz, A. Lazar, e A. Wojas-Pelc, «Dermoscopic features causing confusion between melanoma and benign nevi in clinical diagnosis-case series.», *Pol. Merkur. Lek. Organ Pol. Tow. Lek.*, vol. 49, fasc. 294, pp. 430–433, 2021.
- [9] E. Kalloniati, D. Cavouras, K. M. Plachouri, E. Geropoulou, G. Sakellaropoulos, e S. Georgiou, «Clinical, dermoscopic and histological assessment of melanocytic lesions: a comparative study of the accuracy of the diagnostic methods», *Hippokratia*, vol. 25, fasc. 4, p. 156, 2021.
- [10] J. Y. Chen *et al.*, «Skin Cancer Diagnosis by Lesion, Physician, and Examination Type: A Systematic Review and Meta-Analysis», *JAMA Dermatol.*, vol. 161, fasc. 2, pp. 135–146, feb. 2025, doi: 10.1001/jamadermatol.2024.4382.
- [11] J. Dinnes *et al.*, «Dermoscopy, with and without visual inspection, for diagnosing melanoma in adults», *Cochrane Database Syst. Rev.*, fasc. 12, 2018, doi: 10.1002/14651858.CD011902.pub2.

- [12] M. Giavina-Bianchi, E. Cordioli, e B. S. Machado, *Melanoma: implications of diagnostic failure and perspectives*, vol. 19. SciELO Brasil, 2021, p. eED6680.
- [13] L. Tognetti *et al.*, «Deep learning techniques for the dermoscopic differential diagnosis of benign/malignant melanocytic skin lesions: from the past to the present», *Bioengineering*, vol. 11, fasc. 8, p. 758, 2024.
- [14] D. Huang e M. Feng, «Understanding deep convolutional networks for biomedical imaging: a practical tutorial», in *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, IEEE, 2019, pp. 857–863.
- [15] R. Yamashita, M. Nishio, R. K. G. Do, e K. Togashi, «Convolutional neural networks: an overview and application in radiology», *Insights Imaging*, vol. 9, fasc. 4, pp. 611–629, 2018.
- [16] A. S. Al-Waisy, S. Al-Fahdawi, M. I. Khalaf, M. A. Mohammed, B. Al-Attar, e M. N. Al-Andoli, «A deep learning framework for automated early diagnosis and classification of skin cancer lesions in dermoscopy images», *Sci. Rep.*, vol. 15, fasc. 1, p. 31234, 2025.
- [17] A. Adebiyi *et al.*, «Comparison of three deep learning models in accurate classification of 770 dermoscopy skin lesion images», *AMIA Summits Transl. Sci. Proc.*, vol. 2024, p. 46, 2024.
- [18] S. Alzahrani, B. Al-Bander, e W. Al-Nuaimy, «A comprehensive evaluation and benchmarking of convolutional neural networks for melanoma diagnosis», *Cancers*, vol. 13, fasc. 17, p. 4494, 2021.
- [19] J. Yee, C. Rosendahl, e L. G. Aoude, «The role of artificial intelligence and convolutional neural networks in the management of melanoma: a clinical, pathological, and radiological perspective», *Melanoma Res.*, vol. 34, fasc. 2, p. 96, 2023.
- [20] A. Bhagat, «Two-Stage Fine-Tuning of ResNet50 for High-Sensitivity Melanoma Detection on Dermoscopic Images», *ArXiv Prepr. ArXiv260617504*, 2026.
- [21] A. Faghihi, M. Fathollahi, e R. Rajabi, «Diagnosis of skin cancer using VGG16 and VGG19 based transfer learning models», *Multimed. Tools Appl.*, vol. 83, fasc. 19, pp. 57495–57510, 2024.
- [22] M. Kreouzi *et al.*, «Deep learning for melanoma detection: a deep learning approach to differentiating malignant melanoma from benign melanocytic nevi», *Cancers*, vol. 17, fasc. 1, p. 28, 2024.
- [23] M. Combalia *et al.*, «Validation of artificial intelligence prediction models for skin cancer diagnosis using dermoscopy images: the 2019 International Skin Imaging Collaboration Grand Challenge», *Lancet Digit. Health*, vol. 4, fasc. 5, pp. e330–e339, 2022.

- [24] H. K. Jeong, C. Park, R. Henao, e M. Kheterpal, «Deep learning in dermatology: a systematic review of current approaches, outcomes, and limitations», *Jid Innov.*, vol. 3, fasc. 1, p. 100150, 2023.
- [25] C. Chen, N. A. M. Isa, e X. Liu, «A review of convolutional neural network based methods for medical image classification», *Comput. Biol. Med.*, vol. 185, p. 109507, 2025.
- [26] «Kaggle dataset derivante da ISIC archive». [Online]. Disponibile su: <https://www.kaggle.com/datasets/fanconic/skin-cancer-malignant-vs-benign>
- [27] G. Sacilotto, *GitHub repository for melanoma binary classification using CNNs: Vgg16, Resnet50, DenseNet121*. [Online]. Disponibile su: <https://github.com/gretasacilotto/Automated-Dermoscopic-Image-Classification-with-CNNs-for-melanoma-detection>

Lista di figure

Figura 1. Grafico delle medie delle metriche ottenute dalla cross-validation a 3 fold nella prima fase sperimentale.

Figura 2. Boxplot dell'accuracy nella prima fase sperimentale.

Figura 3. Boxplot della sensitivity nella prima fase sperimentale.

Figura 4. Boxplot della specificity nella prima fase sperimentale.

Figura 5. Boxplot della AUC nella prima fase sperimentale.

Figura 6. Boxplot della F1 score nella prima fase sperimentale.

Figura 7. Confusion-matrix dei 3 fold di Vgg16 nella prima fase sperimentale.

Figura 8. Confusion-matrix dei 3 fold di ResNet50 nella prima fase sperimentale.

Figura 9. Confusion-matrix dei 3 fold di DenseNet121 nella prima fase sperimentale.

Figura 10. Roc-Curve dei 3 fold di Vgg16 nella prima fase sperimentale.

Figura 11. Roc-Curve dei 3 fold di ResNet50 nella prima fase sperimentale.

Figura 12. Roc-Curve dei 3 fold di DenseNet50 nella prima fase sperimentale.

Figura 13. Grafico delle medie delle metriche ottenute dalla cross-validation a 3 fold nella seconda fase sperimentale.

Figura 14. Boxplot dell'accuracy nella seconda sperimentale.

Figura 15. Boxplot della sensitivity nella seconda fase sperimentale.

Figura 16. Boxplot della specificity nella seconda fase sperimentale.

Figura 17. Boxplot della AUC nella seconda fase sperimentale.

Figura 18. Boxplot della F1 nella seconda fase sperimentale.

Figura 19. Confusion-matrix dei 3 fold di Vgg16 nella seconda fase sperimentale.

Figura 20. Confusion-matrix dei 3 fold di ResNet50 nella seconda fase sperimentale.

Figura 21. Confusion-matrix dei 3 fold di DenseNet121 nella seconda fase sperimentale.

Figura 22. Heat-map comparativa delle prime tre lesioni benigne nella prima fase sperimentale.

Figura 23. Heat-map comparativa delle prime tre lesioni maligne nella prima fase sperimentale.

Figura 24. Heat-map comparativa delle prime tre lesioni benigne nella seconda fase sperimentale per Vgg16 e DenseNet121.

Figura 25. Heat-map comparativa delle prime tre lesioni benigne ottenute da ResNet50 nella seconda fase sperimentale.

Figura 26. Heat-map comparativa delle prime tre lesioni maligne nella seconda fase sperimentale per Vgg16 e DenseNet121.

Figura 27. Heat-map comparativa delle prime tre lesioni maligne ottenute da ResNet50 nella seconda fase sperimentale.

Lista di tabelle

Tabella 0. Sottotipi istologici di melanoma.

Tabella 2. Sensibilità e specificità dell'esame clinico visivo per la diagnosi di melanoma.

Tabella 3. Sensibilità e specificità della dermoscopia per la diagnosi di melanoma.

Tabella 4. Struttura della matrice di confusione.

Tabella 5. Valori delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.

Tabella 6. Valori delle medie delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella prima fase sperimentale.

Tabella 7. Valori delle metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda fase sperimentale di ottimizzazione.

Tabella 8. Valori delle medie metriche ottenute dalla cross-validation a 3 fold di Vgg16, ResNet50 e DenseNet121 nella seconda fase sperimentale di ottimizzazione.

Ringraziamenti

In questo capitolo finale vorrei ringraziare tutti coloro che hanno permesso il raggiungimento di questo obiettivo.

Come prima cosa vorrei ringraziare il professor Alberto Antonietti e il professor Juan Pedro Dominguez-Morales che, grazie ai loro preziosi consigli, hanno permesso lo sviluppo e la creazione di questo progetto.

Vorrei poi ringraziare i miei genitori che durante tutto il percorso mi hanno supportata e convinta a continuare e non mollare nonostante le difficoltà.

Infine, vorrei ringraziare i miei amici che mi hanno accompagnata durante tutti questi anni rendendo ogni sfida più leggera e piacevole.

Un ringraziamento speciale va ai miei compagni di corso, sia quelli conosciuti fin dai primi giorni che quelli incontrati lungo il percorso.

